
Universidad Finis Terrae
Facultad de Ingeniería
Ciencia de Datos

Sistema de análisis de datos inmobiliarios

Entrega Final Proyecto de Ciencia de Datos

N° Grupo:

01

Alumnos:

Díaz Matías

Madariaga Felipe

Olmedo Alonso

Urcia Johann

Profesor(a):

Mauricio Hidalgo

Ayudante:

Giacomo Zuñiga

Asignatura:

Ciencia de Datos

NRC:

2528970

4 de septiembre de 2026

Índice

1. Introducción	2
2. Descripción del problema	3
3. Solución Propuesta	4
3.1. Etapas de la propuesta de solución	4
3.1.1. Carga y preparación de datos	4
3.1.2. Análisis exploratorio de datos (EDA)	4
3.1.3. Modelos predictivos	4
3.1.4. Reducción de dimensionalidad y selección de atributos	4
3.1.5. Visualización y presentación de los resultados	5
3.2. Diagrama visual del flujo de la solución propuesta	5
3.3. Alcances y limitaciones	5
4. Listado y descripción de funcionalidades	6
5. Plan de trabajo	8
5.1. Work Breakdown Structure (WBS)	8
5.2. Descripción de Roles	8
5.3. Estimación de tiempo y esfuerzo	9
5.4. Carta Gantt	9
6. Desarrollo de la solución	10
6.1. Carga y limpieza de datos	10
6.2. Análisis exploratorio de datos (EDA)	14
6.3. Aplicación de modelos predictivos	22
6.4. Reducción de dimensionalidad y comparación de modelos predictivos	25
6.5. Dashboards	28
7. Manual de instalación	31
7.1. Requisitos previos	31
7.2. Pasos de instalación y ejecución	31
7.3. Notas adicionales	32
8. Manual de uso	33
8.1. ¿Qué puede hacer el sistema?	33
8.2. ¿Cómo usar el sistema paso a paso?	33
8.3. Posibles errores y advertencias	34
9. Conclusión	35
10. Bibliografía	36

1. Introducción

En el dinámico y competitivo mercado inmobiliario chileno, comprender los factores que determinan el valor de las propiedades es fundamental para la toma de decisiones estratégicas. Las empresas administradoras de bienes raíces requieren herramientas analíticas que les permitan estimar precios de forma precisa y basada en evidencia, considerando variables como ubicación, superficie, número de habitaciones, antigüedad, entre otras. Sin embargo, la complejidad del mercado y la cantidad de datos disponibles dificultan identificar patrones consistentes y formular criterios objetivos de valorización.

Se busca el desarrollo de un sistema de análisis de precios de viviendas en Chile, utilizando técnicas estadísticas y modelos de aprendizaje automático. A partir del análisis del dataset entregado, se aplicarán distintas etapas del proceso: limpieza de datos, análisis exploratorio univariado y multivariado, modelado predictivo y visualización de resultados[2]. Todo esto permitirá predecir de forma precisa el precio de venta de un departamento en función de sus características específicas, proporcionando así una solución útil para la gestión y toma de decisiones en el rubro inmobiliario.

La metodología seguida en este trabajo está alineada con los contenidos tratados en el curso, incluyendo la aplicación de modelos de regresión, métricas estadísticas, técnicas de reducción de dimensionalidad y herramientas de visualización. En conjunto, estos elementos conforman un enfoque robusto e interpretativo para abordar un problema real con impacto práctico en la industria.

En este informe se abordan tanto los aspectos técnicos del desarrollo del sistema como sus fundamentos estadísticos. Se incluye una descripción detallada del problema, la solución propuesta, las funcionalidades del sistema y el plan de trabajo llevado a cabo. Además, se incorporan manuales de instalación y uso que permiten replicar y aplicar la solución, finalizando con una reflexión sobre los resultados obtenidos y las referencias que respaldan el desarrollo realizado.

2. Descripción del problema

El principal problema planteado del mercado inmobiliario chileno es la dificultad para predecir de manera precisa y objetiva el precio de venta de una propiedad, debido a la gran cantidad de variables que influyen en su valorización, como la ubicación, superficie, número de habitaciones, cantidad de baños, disponibilidad de estacionamiento, año de construcción, entre otras. Esta variedad de factores dificulta la creación de criterios objetivos y consistentes para estimar el valor de una propiedad, lo que limita la capacidad de los actores del sector para realizar análisis precisos y tomar decisiones fundamentadas.

El usuario principal afectado por esta problemática son las empresas administradoras de bienes raíces y los agentes inmobiliarios, quienes deben tomar decisiones comerciales fundadas en datos confiables. Para ellos, la imposibilidad de identificar patrones consistentes de valorización implica una mayor probabilidad de cometer errores de estimación, subvaloración o sobrevaloración de propiedades, afectando directamente la rentabilidad de sus operaciones y su capacidad de responder de forma competitiva a un mercado dinámico.

Además, los compradores particulares también se ven perjudicados, ya que al no contar con herramientas objetivas de análisis, deben basarse en criterios subjetivos como referencias informales o precios listados en portales web. Esto puede llevarlos a pagar precios por encima del valor real o perder oportunidades de inversión convenientes. La falta de información estructurada y accesible profundiza así la asimetría del mercado, exponiéndolos a mayores riesgos financieros y decisiones poco informadas.

Esta situación pone en evidencia la necesidad de una solución tecnológica que permita modelar y predecir el valor de una propiedad en función de sus atributos. Un sistema analítico basado en datos reales y modelos predictivos puede reducir la incertidumbre, mejorar la precisión en las estimaciones y fortalecer la toma de decisiones tanto para profesionales del rubro como para compradores e inversionistas.

3. Solución Propuesta

Para abordar el problema planteado en el proyecto, se propone el desarrollo de un sistema de análisis automatizado de precios de viviendas en Chile. Este sistema está orientado a detectar los factores más influyentes en el valor de los departamentos y permitir la predicción de precios en función de características clave. A su vez, el sistema será implementado en Google Colab y Python, debido a su facilidad de uso mediante bloques de código y la disponibilidad de librerías adecuadas para lo requerido.

3.1. Etapas de la propuesta de solución

La solución se estructura en las siguientes etapas, cada una de las cuales busca abordar una parte del proyecto para lograr el objetivo final de forma más concreta y efectiva:

3.1.1. Carga y preparación de datos

El sistema deberá iniciar con la correcta importación del dataset correspondiente (“viviendas_chile.csv”), para posteriormente realizar una exploración básica del mismo. Luego de cargar el dataset, se procederá a una limpieza de los datos, tratando valores duplicados, identificando valores nulos y, en caso de existir, aplicando técnicas adecuadas para su tratamiento. Este proceso es fundamental para garantizar la calidad y confiabilidad del análisis y modelado posterior, ya que datos sucios pueden llevar a conclusiones erróneas [1]. Finalmente, se determinarán de forma preliminar, y considerando el contexto, las variables que podrían resultar importantes para el análisis que se realizará más adelante.

3.1.2. Análisis exploratorio de datos (EDA)

Una vez preparado el dataset, se aplicarán distintas técnicas de análisis exploratorio. Primero se realizará un análisis univariado para examinar la distribución de las variables numéricas y la frecuencia de las variables categóricas. Posteriormente, se efectuará un análisis multivariado con el objetivo de detectar relaciones entre las distintas variables del dataset. Para ello se utilizarán visualizaciones como histogramas, boxplots, gráficos de densidad, scatterplots, heatmaps y pairplots. Todo esto permitirá formular hipótesis iniciales e identificar cuáles variables tienen mayor impacto en la futura implementación de los modelos predictivos.

3.1.3. Modelos predictivos

Con las variables pertinentes ya identificadas, se implementarán tres modelos predictivos: regresión lineal, regresión logística y KNN. Posteriormente, se evaluará el desempeño de cada modelo mediante distintas métricas, con el fin de seleccionar el que entregue los mejores resultados en la predicción de precios de las viviendas en función de las características seleccionadas gracias al EDA.

3.1.4. Reducción de dimensionalidad y selección de atributos

En esta etapa se aplicarán técnicas para reducir las dimensiones del dataset y seleccionar los atributos más relevantes. Se utilizarán herramientas como el análisis de com-

ponentes principales (PCA), el análisis de determinante lineal (LDA) y la correlación canónica (CCA). Esto permitirá determinar qué características son más influyentes en la determinación del precio de los departamentos y optimizar el rendimiento de los modelos aplicados.

3.1.5. Visualización y presentación de los resultados

Finalmente, con un análisis exploratorio completo y el mejor modelo predictivo entrenado, se desarrollará un dashboard de visualización para comunicar los resultados más relevantes. Este incluirá gráficos obtenidos en el análisis exploratorio que justifiquen la selección del modelo, además de tablas estadísticas, representaciones visuales y pruebas que demuestren el correcto funcionamiento del modelo predictivo. Adicionalmente, se elaborará un informe final que recopile todo lo desarrollado en las etapas anteriores, con una presentación formal y estructurada que refleje la calidad del trabajo realizado.

3.2. Diagrama visual del flujo de la solución propuesta

Todas estas etapas derivan en un diagrama visual del flujo de la solución propuesta de la siguiente manera:




Figura 1: Diagrama lógico de la solución

3.3. Alcances y limitaciones

La solución propuesta permitirá realizar un análisis automatizado de precios de departamentos en Chile utilizando técnicas estadísticas y modelos predictivos en Python. Abarca todo el proceso de análisis de datos: desde la carga y limpieza del dataset, hasta la construcción y evaluación de modelos de regresión. El sistema puede identificar variables relevantes en la determinación del precio y predecir dicho valor a partir de características estructurales como superficie, cantidad de habitaciones y baños, entre otras. Además, la visualización final facilita la interpretación de los resultados por parte de usuarios no técnicos.

A pesar de ello, el rendimiento del sistema depende directamente de la calidad y representatividad del dataset utilizado. No se consideran variables externas como ubicación geográfica exacta, entorno socioeconómico, acceso a servicios, ni aspectos temporales como inflación o variación del mercado inmobiliario en el tiempo. Tampoco se incluyen imágenes ni texto descriptivo de las propiedades. Por último, al utilizar modelos supervisados clásicos, se privilegia la interpretabilidad por sobre la complejidad, lo cual puede afectar la precisión en ciertos contextos reales.

4. Listado y descripción de funcionalidades

A continuación, se describen las funcionalidades implementadas y planificadas del sistema de análisis de precios de viviendas. Cada funcionalidad toma en consideración el rol del usuario, su propósito dentro del proyecto y el estado actual de desarrollo.

■ Carga y limpieza de datos

Usuario: Equipo desarrollador encargado del procesamiento y limpieza de datos.

Objetivo: Importar y preparar el dataset con información de propiedades en venta (precio, ubicación, superficie, habitaciones, etc.).

Motivo: Garantizar que los datos sean completos, limpios y estén listos para su análisis.

Estado: Completado

■ Análisis exploratorio univariado

Usuario: Nosotros como analistas responsables del estudio inicial de las variables.

Objetivo: Calcular métricas estadísticas como media, mediana, desviación estándar y percentiles para comprender la distribución de cada variable.

Motivo: Detectar valores atípicos y obtener una visión inicial del comportamiento de las variables.

Estado: Completado

■ Análisis exploratorio multivariado

Usuario: Equipo desarrollador encargado de analizar relaciones multivariadas.

Objetivo: Explorar la relación entre múltiples variables (por ejemplo, precio vs superficie o año de construcción).

Motivo: Identificar patrones, correlaciones y dependencias útiles para la modelación.

Estado: Completado

■ Aplicación de modelos predictivos

Usuario: Nosotros como desarrolladores e implementadores de modelos predictivos.

Objetivo: Estimar el precio de una propiedad utilizando modelos de regresión lineal, logística y KNN.

Motivo: Automatizar y mejorar la predicción de precios a partir de características cuantificables.

Estado: Completado

- **Evaluación comparativa de modelos**

Usuario: Equipo desarrollador que evalúa modelos para recomendar la mejor alternativa.

Objetivo: Evaluar los modelos mediante métricas como MAE, RMSE y precisión.

Motivo: Seleccionar el modelo más adecuado según el rendimiento observado.

Estado: Completado

- **Reducción de dimensionalidad**

Usuario: Equipo técnico a cargo de aplicar técnicas estadísticas de reducción dimensional.

Objetivo: Aplicar técnicas como PCA, LDA o CCA para disminuir el número de variables sin perder información relevante.

Motivo: Mejorar la eficiencia de los modelos y eliminar redundancia.

Estado: Completado

- **Selección de atributos relevantes**

Usuario: Nosotros como responsables del análisis de impacto de variables en el modelo.

Objetivo: Determinar las variables con mayor impacto en el precio de las propiedades.

Motivo: Optimizar el desempeño y la interpretabilidad del modelo.

Estado: Completado

- **Generación de reportes y visualización de resultados**

Usuario: Nosotros como encargados de elaborar visualizaciones y reportes para facilitar la toma de decisiones.

Objetivo: Mostrar hallazgos del análisis a través de gráficos, dashboards y tablas.

Motivo: Facilitar la interpretación visual y presentación ejecutiva de resultados.

Estado: Completado

5. Plan de trabajo

5.1. Work Breakdown Structure (WBS)

A continuación se presenta el WBS, que ayudará a planificar de mejor manera las actividades y tareas generales del proyecto.

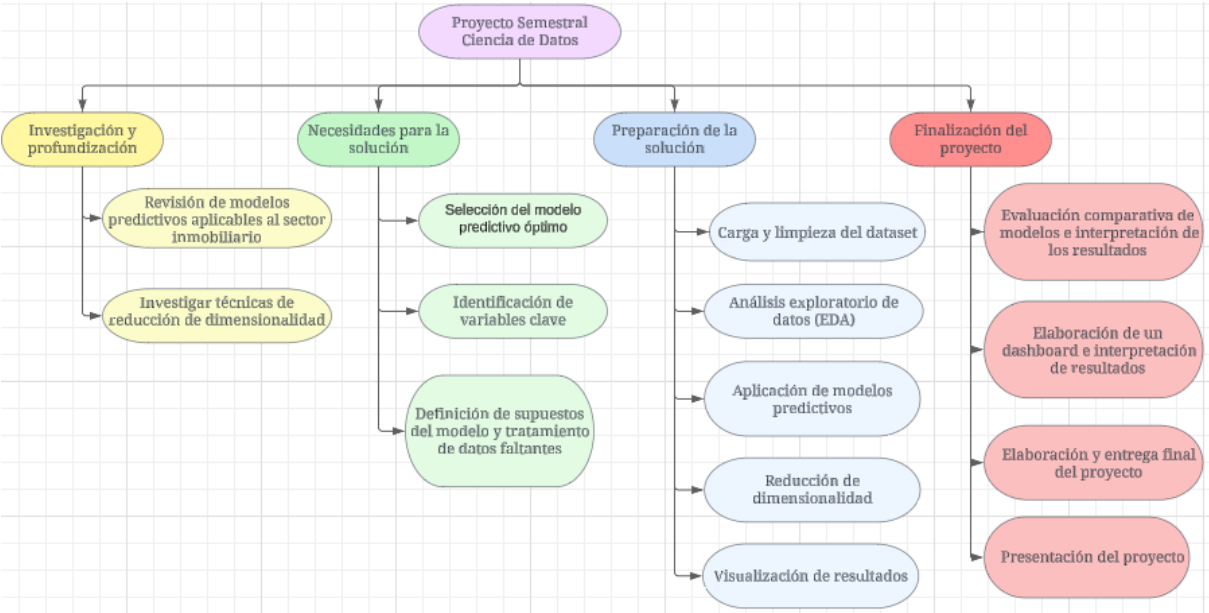


Figura 2: Work Breakdown Structure

5.2. Descripción de Roles

A cada integrante se le asignó un rol para cada tarea, designado así:

- 1. A, son los encargados de asegurarse que la tarea se lleve a cabo.
- 2. B, son los que realizarán aquella tarea.
- 3. C, son los que brindaran apoyo al encargado de realizar la tarea.
- 4. D, son los que deben estar informados sobre cómo va la tarea y el resultado de esta.

Actividades	A. Olmedo	F. Madariaga	J. Urcia	M. Diaz	N. Dylan
Investigación y profundización	A				
Revisión de modelos predictivos aplicables al sector inmobiliario	C	B	C	D	D
Investigar técnicas de reducción de dimensionalidad	D	C	C	C	B
Necesidades para la solución	A				
Selección del modelo predictivo óptimo (regresión lineal, logística, KNN)	B	C	C	C	D
Identificación de variables clave	D	D	B	D	C
Definición de supuestos del modelo y tratamiento de datos faltantes	C	D	C	B	D
Preparación de la solución			A		
Carga y limpieza del dataset	D	C	C	B	D
Análisis exploratorio de datos (EDA)	B	C	D	D	B
Aplicación de modelos predictivos	B	C	B	C	D
Reducción de dimensionalidad (PCA, LDA)	C	D	B	B	C
Visualización de resultados	B	D	C	A	C
Finalización del proyecto				A	
Evaluación comparativa de modelos e interpretación de los resultados	D	C	B	C	B
Elaboración de un dashboard e interpretación de resultados	B	D	C	B	D
Elaboración y entrega final del proyecto	C	C	D	B	D

Figura 3: Descripción de roles

5.3. Estimación de tiempo y esfuerzo

Ahora se presenta una tabla para poder tener más clara una estimación en tema tiempo y personas que llevarán a cabo este proyecto.

Fases	Actividades	Esfuerzo (HH)	Recursos
Investigación y profundización	Revisión de modelos predictivos aplicables al sector inmobiliario	12	2
	Investigar técnicas de reducción de dimensionalidad	10	2
Investigación y profundización	Selección del modelo predictivo óptimo (regresión lineal, logística, KNN)	8	3
	Identificación de variables clave	8	2
	Definición de supuestos del modelo y tratamiento de datos faltantes	6	4
Preparación de la solución	Carga y limpieza del dataset	8	2
	Análisis exploratorio de datos (EDA)	12	4
	Aplicación de modelos predictivos	10	2
	Reducción de dimensionalidad (PCA, LDA)	12	3
	Visualización de resultados	6	3
Finalización del proyecto	Evaluación comparativa de modelos e interpretación de los resultados	8	3
	Elaboración de un dashboard e interpretación de resultados	9	3
	Elaboración y entrega final del proyecto	15	4

Figura 4: Estimación tiempo/esfuerzo

5.4. Carta Gantt

Por último, se muestra la carta Gantt que ayudará a entender en tema tiempo la duración de cada tarea.

		Semanas											
		1	2	3	4	5	6	7	8	9	10	11	12
		28.03 - 30.03	31.03 - 06.04	07.04 - 13.04	14.04 - 20.04	21.04 - 27.04	28.04 - 04.05	05.05 - 11.05	12.05 - 18.05	19.05 - 25.05	26.05 - 01.06	02.06 - 08.06	09.06 - 14.06
Actividades	Depende de												
Investigación y profundización													
Revisión de modelos predictivos aplicables al sector inmobiliario	N/A	■	■	■									
Investigar técnicas de reducción de dimensionalidad para datos inmobiliarios	Revisión de modelos predictivos aplicables al sector inmobiliario		■	■	■								
Necesidades para la solución													
Selección del modelo predictivo óptimo (regresión lineal, logística, KNN)	Actividades de investigación y profundización				■	■	■						
Identificación de variables clave	Selección del modelo predictivo óptimo						■						
Definición de supuestos del modelo y tratamiento de datos faltantes	Identificación de variables clave							■	■	■			
Preparación de la solución													
Carga y limpieza del dataset	N/A								■	■			
Análisis exploratorio de datos (EDA)	Carga y limpieza del dataset								■	■	■		
Aplicación de modelos predictivos	Análisis exploratorio de datos (EDA)										■	■	
Reducción de dimensionalidad (PCA, LDA)	Análisis exploratorio de datos (EDA)											■	■
Visualización de resultados	Aplicación de modelos predictivos y reducción de dimensionalidad												■
Finalización del proyecto													
Evaluación comparativa de modelos e interpretación de los resultados	Visualización de resultados											■	■
Elaboración de un dashboard e interpretación de resultados	Evaluación comparativa de modelos e interpretación de los resultados											■	■
Elaboración y entrega final del proyecto	Elaboración de un dashboard e interpretación de resultados	■	■	■	■	■	■	■	■	■	■	■	■
Presentación del proyecto	Elaboración y entrega final del proyecto												■

Figura 5: Carta Gantt

6. Desarrollo de la solución

En esta sección se detalla la implementación práctica del sistema de análisis de precios inmobiliarios en Chile. Cada etapa fue desarrollada utilizando Python en Google Colab, desde la carga inicial del conjunto de datos hasta la estandarización de variables necesarias para el análisis. A través del uso de librerías especializadas en ciencia de datos y visualización, se construyó un flujo de trabajo reproducible que permite comprender y modelar el comportamiento de los precios de los departamentos.

Se presentan los bloques de código utilizados junto con sus respectivas salidas, análisis interpretativo y fundamentos metodológicos. Esto garantiza la trazabilidad del proceso y permite validar cada una de las decisiones tomadas en términos de limpieza, transformación, análisis exploratorio y preparación para modelos predictivos.

6.1. Carga y limpieza de datos

En esta etapa se cargó correctamente el conjunto de datos desde Google Drive y se aplicaron técnicas básicas de limpieza, como la eliminación de registros no relevantes, la conversión de variables categóricas a numéricas y la preparación del dataset para el análisis exploratorio posterior.

```
1 #1. Carga y limpieza de datos
2
3 ## a. Importar un conjunto de datos de propiedades en venta
4 from google.colab import drive
5 import pandas as pd
6 import matplotlib.pyplot as plt
7 import seaborn as sns
8 import numpy as np
9 from IPython.display import display
10 from sklearn.model_selection import train_test_split
11 from sklearn.linear_model import LinearRegression
12 from sklearn.neighbors import KNeighborsRegressor
13 from sklearn.metrics import mean_squared_error, mean_absolute_error
14     , r2_score
15 from sklearn.preprocessing import StandardScaler
16 from sklearn.decomposition import PCA
17 from sklearn.discriminant_analysis import
18     LinearDiscriminantAnalysis as LDA
19
20 # Montar y cargar
21 try:
22     drive.mount('/content/drive')
23     ruta = '/content/drive/My Drive/Colab Notebooks/Proyecto -
24         Ciencia de Datos/viviendas_chile.csv'
25     data = pd.read_csv(ruta, delimiter=',')
26     print("\n Datos cargados correctamente\n")
27 except Exception as e:
```

```

25     print(f"\n Error al cargar el archivo: {e}\n")
26
27 ## b. Aplicar técnicas de limpieza de datos
28 print("Primeras filas del dataset:")
29 display(data.head())
30
31 print("\nResumen del DataFrame:")
32 data.info()
33
34 print("\nValores nulos por columna:")
35 print(data.isnull().sum())
36
37 print(f"\nDuplicados: {data.duplicated().sum()}")
38
39 # Filtrar solo departamentos
40 data = data[data["Tipo Propiedad"].str.lower() == "departamento"]
41
42 # === Preprocesamiento para EDA ===
43 data["Estacionamiento_bin"] = data["Estacionamiento"].map({"Si": 1,
44     "Sí": 1, "No": 0})
44 data["Bodega_bin"] = data["Bodega"].map({"Si": 1, "Sí": 1, "No":
45     0})

```

Código 1: Carga y limpieza de datos

Al ejecutar este código se obtiene la siguiente salida, que se analiza punto por punto:

Primeras filas del dataset:

	ID	Región	Comuna	Tipo Propiedad	Precio	Metros Totales	\
0	1	Coquimbo	La Serena	Terreno	182546501	142	
1	2	Araucanía	Temuco	Casa	185667421	30	
2	3	Coquimbo	La Serena	Departamento	387368371	287	
3	4	Valparaíso	Valparaíso	Departamento	465340305	219	
4	5	Los Lagos	Puerto Montt	Terreno	485416587	175	

	Metros Útiles	Habitaciones	Baños	Estacionamiento	Bodega	Año Construcción
0	112	3	2	Sí	No	1982
1	23	2	2	Sí	No	2022
2	274	5	2	Sí	Sí	2013
3	214	1	3	Sí	Sí	1984
4	162	5	2	Sí	Sí	1989

Estas primeras filas muestran correctamente las variables requeridas por el proyecto: ubicación, precio, metros cuadrados, número de habitaciones y año de construcción, entre otros.

Luego se muestra un resumen de dataset con `.info()`:

#	Columna	Non-Null Count	Tipo de Dato
0	ID	10000	int64
1	Región	10000	object
2	Comuna	10000	object
3	Tipo Propiedad	10000	object
4	Precio	10000	int64
5	Metros Totales	10000	int64
6	Metros Útiles	10000	int64
7	Habitaciones	10000	int64
8	Baños	10000	int64
9	Estacionamiento	10000	object
10	Bodega	10000	object
11	Año Construcción	10000	int64

Cuadro 1: Resumen del DataFrame con `.info()`

Esta tabla muestra que tenemos claramente 10000 valores no nulos por cada variable y que cada una tiene su tipo de dato correspondiente. Indicando por lo tanto que el data set tiene un total de 10000 filas a analizar.

Luego, cuenta e imprime los valores nulos por cada variable mostrandose a continuación en la siguiente tabla:

Columna	Valores Nulos
ID	0
Región	0
Comuna	0
Tipo Propiedad	0
Precio	0
Metros Totales	0
Metros Útiles	0
Habitaciones	0
Baños	0
Estacionamiento	0
Bodega	0
Año Construcción	0

Cuadro 2: Cantidad de valores nulos por columna en el dataset original

Con esta tabla, se confirma que no existen valores nulos en el conjunto de datos, por lo que no se requieren imputaciones.

Luego se imprimen la cantidad de valores duplicados, siendo estos 0, por lo tanto no requiriendo eliminación de los mismos.

Duplicados: 0

Luego, en el código, se muestra cómo se filtra el dataset solo para tomar las filas que sean correspondientes a departamento, que es lo requerido en el proyecto, para posteriormente imprimir las primeras 5 filas y verificar que funcionó correctamente:

ID	Región	Comuna	Tipo	Precio	Totales	Útiles
3	Coquimbo	La Serena	Departamento	387,368,371	287	274
4	Valparaíso	Valparaíso	Departamento	465,340,305	219	214
6	Biobío	Los Ángeles	Departamento	239,989,338	296	283
22	Coquimbo	La Serena	Departamento	371,066,384	159	151
32	Valparaíso	Valparaíso	Departamento	438,380,499	50	31

Hab.	Baños	Estac.	Bodega	Año Const.
5	2	Sí	Sí	2013
1	3	Sí	Sí	1984
5	2	No	No	1950
1	2	Sí	No	2008
5	2	No	No	1972

Cuadro 3: `.head()` tras filtrar por Tipo Propiedad = Departamento

Verificando con ello y un `.shape` que los datos totales pasaron de 10000 a 2546, tras filtrar por departamento.

Por último en el bloque de código se realizó un preprocesamiento básico de variables categóricas, convirtiendo las columnas Estacionamiento y Bodega a formato binario. Esto facilita su análisis en el EDA posterior y su incorporación en modelos predictivos.

6.2. Análisis exploratorio de datos (EDA)

En esta etapa se calculan estadísticas descriptivas, se aplican visualizaciones y se preparan nuevas variables con el objetivo de comprender la distribución de los datos, identificar patrones relevantes y detectar posibles valores atípicos. Este análisis permite fundamentar decisiones posteriores en el modelado y mejorar la calidad de las predicciones.

```
1 #2. Análisis exploratorio de datos (EDA)
2
3 ## a. Calcular métricas descriptivas
4 print("\nMétricas del Precio:")
5 precio = data["Precio"]
6 print(f"Media: ${precio.mean():,.0f}")
7 print(f"Mediana: ${precio.median():,.0f}")
8 print(f"Desviación estándar: ${precio.std():,.0f}")
9 print(f"P25: ${precio.quantile(0.25):,.0f} | P75: ${precio.quantile(
    (0.75):,.0f}")
10
11 ## b. Visualizaciones
12 # Matriz de correlación de variables originales
13 plt.figure(figsize=(10, 6))
14 corr_vars = ["Precio", "Metros Totales", "Metros Útiles", "
    Habitaciones", "Baños", "Año Construcción", "Estacionamiento_bin",
    "Bodega_bin"]
15 sns.heatmap(data[corr_vars].corr(), annot=True, cmap="coolwarm",
    fmt=".2f")
16 plt.title("Matriz de correlación (variables originales)")
17 plt.tight_layout()
18 plt.show()
19
20 # Boxplots para variables categóricas y ordinales
21 for var in ["Habitaciones", "Baños", "Estacionamiento_bin", "
    Bodega_bin"]:
22     plt.figure(figsize=(6, 4))
23     sns.boxplot(x=data[var], y=data["Precio"])
24     plt.title(f"Boxplot de Precio según {var}")
25     plt.tight_layout()
26     plt.show()
27
28 # Histogramas de variables numéricas
29 vars_hist = ["Precio", "Metros Totales", "Metros Útiles", "
    Habitaciones", "Baños"]
30 for var in vars_hist:
31     plt.figure(figsize=(6, 4))
32     sns.histplot(data[var], bins=20, kde=True)
33     plt.title(f"Distribución de {var}")
34     plt.tight_layout()
35     plt.show()
36
```

```

37 # Pairplot
38 sns.pairplot(data[["Precio", "Metros Totales", "Metros Útiles", "
    Habitaciones", "Baños"]])
39 plt.suptitle("Relaciones entre variables numéricas", y=1.02)
40 plt.show()
41
42 ## c. Limpieza y creación de nuevas variables
43 # Convertir columnas necesarias
44 data["Estacionamiento"] = data["Estacionamiento"].map({"Si": 1, "Sí
    ": 1, "No": 0})
45 data["Bodega"] = data["Bodega"].map({"Si": 1, "Sí": 1, "No": 0})
46 to_numeric = ["Precio", "Metros Totales", "Metros Útiles", "
    Habitaciones", "Baños", "Estacionamiento", "Bodega"]
47 for col in to_numeric:
48     data[col] = pd.to_numeric(data[col], errors="coerce")
49
50 # Crear variables derivadas
51 data["Precio_m2"] = data["Precio"] / data["Metros Útiles"]
52
53 # Eliminar outliers
54 for col in ["Precio", "Metros Totales", "Metros Útiles", "Precio_m2
    "]:
55     q1 = data[col].quantile(0.25)
56     q3 = data[col].quantile(0.75)
57     iqr = q3 - q1
58     data = data[(data[col] >= q1 - 1.5 * iqr) & (data[col] <= q3 +
        1.5 * iqr)]
59 print(data.shape)

```

Código 2: Análisis Exploratorio de Datos (EDA)

Luego de ejecutar este código se muestra a continuación cada gráfico y medida realizada con su respectiva descripción:

Métrica	Valor
Media	\$265,896,917
Mediana	\$267,968,678
Desviación estándar	\$135,683,454
Percentil 25 (P25)	\$149,501,128
Percentil 75 (P75)	\$384,554,625

Cuadro 4: Métricas descriptivas del precio de departamentos

Se observa que la media (\$265,896,917) y la mediana (\$267,968,678) son valores cercanos, lo que sugiere que la distribución del precio es aproximadamente simétrica y no presenta sesgos extremos. Sin embargo, la desviación estándar es alta (\$135,683,454), lo cual indica una dispersión considerable en los valores de precio. Además, el rango intercuartílico (entre P25 y P75) abarca más de \$235 millones, lo que evidencia una fuerte variabilidad dentro del 50 % central de los datos. Esta dispersión justifica la necesidad

de aplicar técnicas para la detección y eliminación de valores atípicos antes de entrenar modelos predictivos.

Luego de esto se visualiza la siguiente matriz de correlación:




Figura 6: Matriz de Correlación

De la matriz de correlación se puede interpretar que no existen relaciones lineales fuertes entre la variable Precio y el resto de las variables analizadas. Las correlaciones con Metros Totales y Metros Útiles son prácticamente nulas. Asimismo, variables como Habitaciones, Baños, Estacionamiento_bin y Bodega_bin presentan correlaciones muy bajas (cercanas a 0), lo que sugiere que su efecto sobre el precio podría ser débil o que se necesita un análisis más profundo (como regresión múltiple o técnicas no lineales) para evidenciar su impacto.

Luego se generaron boxplots para variables categóricas y ordinales:




Figura 7: Boxplot Precio Segun Habitantes




Figura 8: Boxplot de Precio Según Baños




Figura 9: Boxplot de Precio Según Estacionamiento_bin




Figura 10: Boxplot de Precio Según Bodega_bin

Se puede observar que el precio de los departamentos presenta una distribución similar en todas las categorías analizadas, lo que coincide con lo mostrado en la matriz de correlación. En el caso de **Habitaciones** y **Baños**, no se aprecia una tendencia clara que indique que más cantidad se asocie con mayor precio, ya que las medianas se mantienen relativamente constantes.

En cuanto a las variables binarias `Estacionamiento_bin` y `Bodega_bin`, los precios también se distribuyen de forma similar entre ambas categorías (0 y 1). Esto refuerza la idea de que, de forma individual, estas variables no tienen un impacto significativo en el precio, aunque podrían cobrar relevancia cuando se combinan con otras características en modelos multivariados.

Esto quiere decir que, los boxplots muestran una forma simétrica, sin sesgos marcados, lo cual respalda que la distribución del precio es aproximadamente normal. Esta observación es útil para justificar el uso de modelos de regresión lineal en etapas posteriores del análisis.

Luego se generaron histogramas de variables numéricas:




Figura 11: Histograma de Precio




Figura 12: Histograma de Metros Totales




Figura 13: Histograma de Metros Útiles




Figura 14: Histograma de Habitaciones




Figura 15: Histograma de Baños

A partir de los histogramas de las variables numéricas, se pueden extraer las siguientes observaciones:

- **Precio:** La distribución del precio es relativamente simétrica, con una ligera tendencia hacia la uniformidad en los rangos. No se observa una concentración clara

en un solo intervalo, lo que indica diversidad en los valores de mercado dentro del dataset.

- **Metros Totales:** Los valores están distribuidos de forma bastante pareja, aunque se observan pequeñas concentraciones hacia los extremos superiores (sobre 250 m²), lo que puede estar influido por propiedades atípicas o de lujo.
- **Metros Útiles:** Presenta una leve asimetría hacia la izquierda (distribución sesgada a la derecha), con una alta frecuencia de departamentos bajo los 50 m². Esto puede representar propiedades tipo estudio o de menor tamaño.
- **Habitaciones:** Se distribuyen de forma prácticamente uniforme entre 1 y 6 habitaciones, sin una categoría claramente predominante. Esto indica una buena representación de distintos tamaños de departamentos.
- **Baños:** Se observa un patrón similar al de habitaciones, con una distribución regular en las 4 categorías posibles. No hay una concentración marcada en un número específico de baños, lo cual puede influir en la flexibilidad de análisis posterior.

En general, las variables numéricas presentan distribuciones manejables, sin sesgos extremos, y son adecuadas para el análisis exploratorio y la aplicación de modelos predictivos. La única excepción parcial podría ser la variable **Metros Útiles**, que requiere una revisión más detallada por su leve asimetría.

Luego aplicamos el siguiente pairplot:




Figura 16: Pairplot

El análisis exploratorio bivariado reveló patrones importantes en la relación entre el precio total de las propiedades y su tamaño. En los gráficos de dispersión entre **Precio** y tanto **Metros Totales** como **Metros Útiles**, se observa una tendencia creciente, pero acompañada de una alta dispersión vertical. Esta dispersión indica que existen numerosos casos en los que propiedades con superficies similares tienen precios considerablemente distintos. En otras palabras, el tamaño por sí solo no explica de manera suficiente la variabilidad del precio.

Este fenómeno puede deberse a diversos factores implícitos: ubicación, estado de conservación, equipamiento, orientación, entre otros. Sin embargo, desde una perspectiva analítica, esta observación plantea la necesidad de normalizar el precio por unidad de superficie útil, a fin de mejorar la comparabilidad entre propiedades de distinto tamaño.

Como respuesta a este hallazgo, se creó la variable derivada **Precio_m2**, definida como el cociente entre el precio total y los metros útiles de la propiedad. Esta transformación tiene múltiples propósitos: permite reducir la variabilidad atribuible únicamente al tamaño, centra el análisis en el valor relativo del metro cuadrado habitable, y favorece la detección de outliers que podrían pasar desapercibidos si se analizara únicamente el precio total.

Además, **Precio_m2** es una métrica ampliamente utilizada en el ámbito inmobiliario real, lo que no solo mejora la interpretación del modelo, sino que también alinea el análisis con prácticas reales del mercado. Se espera que esta variable mejore la capacidad explicativa de los modelos predictivos y contribuya a una segmentación más precisa del valor de las propiedades.

Por otro lado, también se evidenció una relación prácticamente lineal entre **Metros Totales** y **Metros Útiles**, indicando una alta colinealidad entre ambas variables. Dado que esta relación es estructural y esperada (el total construido incluye el espacio útil más áreas no habitables como terrazas o pasillos), se optó por no crear nuevas variables derivadas de esta relación, ni eliminar ninguna de ellas, ya que podrían aportar valor diferenciado en etapas posteriores del modelado. No obstante, se tendrá en consideración esta dependencia durante la selección de atributos, especialmente en modelos sensibles a la multicolinealidad como la regresión lineal.

Luego de crear la variable **Precio_m2** se optó por eliminar los nuevos outliers creados, quedando así con un data set final para el modelado de 2292 filas.

6.3. Aplicación de modelos predictivos

En esta sección se procede a la aplicación de modelos predictivos sobre el conjunto de datos limpio. Si bien se solicitó implementar regresión lineal, regresión logística y KNN, se optó por aplicar únicamente regresión lineal y KNN, ya que la regresión logística está diseñada para problemas de clasificación categórica y no es adecuada para la predicción de variables continuas como el precio de una propiedad.

```

1  #3. Aplicación de modelos predictivos
2
3  ## a. Preparación del modelo
4  model_data = data.copy()
5  dummies = pd.get_dummies(model_data[["Región", "Comuna"]],
6                               drop_first=True)
7  X = pd.concat([model_data[["Metros Útiles", "Habitaciones", "Baños",
8                               "Precio_m2", "Estacionamiento", "Bodega"]], dummies], axis=1)
9  y = model_data["Precio"]
10
11 # División y escalado
12 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size
13                                                    =0.2, random_state=42)
14 scaler = StandardScaler()
15 X_train_scaled = scaler.fit_transform(X_train)
16 X_test_scaled = scaler.transform(X_test)
17
18 ## b. Evaluación de modelos
19
20 def evaluar_modelos(Xtr, Xte, ytr, yte, etiqueta):
21     resultados = []
22
23     # Regresión Lineal
24     lr = LinearRegression()
25     lr.fit(Xtr, ytr)
26     y_pred_lr = lr.predict(Xte)
27     resultados.append({"Reducción": etiqueta, "Modelo": "Regresión
28                       Lineal", "R2": r2_score(yte, y_pred_lr), "MAE":
29                       mean_absolute_error(yte, y_pred_lr), "RMSE": np.sqrt(
30                       mean_squared_error(yte, y_pred_lr))})
31     plt.figure(figsize=(6, 5))
32     plt.scatter(yte, y_pred_lr, alpha=0.5)
33     plt.plot([yte.min(), yte.max()], [yte.min(), yte.max()], 'r--')
34     plt.title(f"Regresión Lineal ({etiqueta})")
35     plt.xlabel("Precio Real")
36     plt.ylabel("Precio Predicho")
37     plt.tight_layout()
38     plt.grid()
39     plt.show()
40
41 # KNN

```

```
36 knn = KNeighborsRegressor(n_neighbors=5)
37 knn.fit(Xtr, ytr)
38 y_pred_knn = knn.predict(Xte)
39 resultados.append({"Reducción": etiqueta, "Modelo": "KNN", "R2"
    : r2_score(yte, y_pred_knn), "MAE": mean_absolute_error(yte,
    y_pred_knn), "RMSE": np.sqrt(mean_squared_error(yte,
    y_pred_knn))})
40 plt.figure(figsize=(6, 5))
41 plt.scatter(yte, y_pred_knn, alpha=0.5)
42 plt.plot([yte.min(), yte.max()], [yte.min(), yte.max()], 'r--')
43 plt.title(f"KNN Regressor ({etiqueta})")
44 plt.xlabel("Precio Real")
45 plt.ylabel("Precio Predicho")
46 plt.tight_layout()
47 plt.grid()
48 plt.show()
49
50 return resultados
```

Código 3: Aplicación de modelos predictivos

Para aplicar los modelos predictivos, primero se realizó una copia del conjunto de datos limpio, preservando así la integridad del original. Luego, se definieron las variables independientes (predictoras) y la variable dependiente (objetivo). En este caso, la variable objetivo seleccionada fue el **Precio** de la propiedad, mientras que como variables predictoras se incluyeron características estructurales relevantes como **Metros Útiles**, **Habitaciones**, **Baños**, **Precio_m2**, **Estacionamiento** y **Bodega**, ya que todas ellas fueron previamente identificadas como potencialmente influyentes en el valor de una propiedad.

Cabe señalar que, aunque también se disponía de la variable **Metros Totales**, se decidió no incluirla simultáneamente con **Metros Útiles** para evitar problemas de multicolinealidad, dado que ambas están altamente correlacionadas. Esta relación fue evidenciada en el análisis exploratorio mediante gráficos de dispersión, y mantener ambas en el modelo podría afectar la estabilidad de los coeficientes en la regresión lineal o introducir redundancia en el modelo KNN. Por ello, se optó por utilizar sólo una de ellas, en este caso, **Metros Útiles** para representar el tamaño de la propiedad de forma eficiente y sin duplicidad estadística.

Además, se incorporaron las variables categóricas **Región** y **Comuna**, las cuales fueron transformadas en variables numéricas mediante el uso de **dummies**. Esta técnica, conocida como codificación one-hot, consiste en convertir categorías en columnas binarias (0 o 1) para que los modelos puedan procesarlas. Se utilizó el parámetro **drop_first=True** para evitar la multicolinealidad entre variables dummy, es decir, eliminar una columna redundante de cada grupo categórico.

Una vez definidas las variables, se concatenaron las columnas numéricas y las dummies, conformando así la matriz **X** de características. Esta matriz fue luego dividida en un conjunto de entrenamiento (80 %) y un conjunto de prueba (20 %), con el objetivo de

evaluar la capacidad de generalización del modelo. Posteriormente, se aplicó un escalado estandarizado a las variables predictoras utilizando `StandardScaler`, lo cual fue especialmente necesario para el algoritmo KNN, ya que este modelo basa sus predicciones en distancias euclidianas, siendo muy sensible a las diferencias de escala entre variables.

En cuanto a la implementación de los modelos, se definió una función llamada `evaluar_modelos()` que recibe como entrada los conjuntos de entrenamiento y prueba, además de una etiqueta descriptiva para el caso evaluado. Dentro de esta función se entrena y evalúa primero un modelo de regresión lineal y luego un modelo KNN con $k = 5$. Para cada uno, se calculan tres métricas de desempeño: el coeficiente de determinación (R^2), el error absoluto medio (MAE) y la raíz del error cuadrático medio (RMSE), que permiten evaluar la precisión y el ajuste del modelo. Adicionalmente, se generan gráficos de dispersión entre los valores reales y los predichos para cada modelo, permitiendo visualizar de manera intuitiva su rendimiento y posibles desviaciones sistemáticas.

6.4. Reducción de dimensionalidad y comparación de modelos predictivos

En esta sección se aplican técnicas de reducción de dimensionalidad con el objetivo de evaluar su impacto sobre el rendimiento de los modelos predictivos. Si bien se solicitó utilizar PCA, LDA y CCA, no se aplicó CCA debido a que esta técnica requiere dos conjuntos de variables con correspondencia entre sí, lo cual no se cumple en este caso. Por tanto, se optó por aplicar únicamente PCA y LDA, transformando el conjunto original de variables en nuevos espacios reducidos. Luego, se compararon los resultados obtenidos frente a los modelos entrenados sin reducción, utilizando las mismas métricas de evaluación para facilitar el análisis comparativo.


```
1 #4. Reducción de dimensionalidad y selección de atributos
2
3 ## a. PCA
4 pca = PCA(n_components=0.99)
5 X_train_pca = pca.fit_transform(X_train_scaled)
6 X_test_pca = pca.transform(X_test_scaled)
7 res_pca = evaluar_modelos(X_train_pca, X_test_pca, y_train, y_test,
8                             "PCA")
9
10 ## b. LDA
11 y_clas = pd.cut(y, bins=np.arange(0, 520_000_000, 50_000_000),
12                 labels=False)
13 lda = LDA(n_components=2)
14 X_train_lda = lda.fit_transform(X_train_scaled, y_clas[y_train.
15                                 index])
16 X_test_lda = lda.transform(X_test_scaled)
17 res_lda = evaluar_modelos(X_train_lda, X_test_lda, y_train, y_test,
18                             "LDA")
19
20 # c. Comparación de modelos (sin reducción)
21 res_sin_red = evaluar_modelos(X_train_scaled, X_test_scaled,
22                               y_train, y_test, "Sin reducción")
23
24 # Resultados finales
25 resultados = pd.DataFrame(res_sin_red + res_pca + res_lda).round(3)
26 print("\n Comparación de modelos:")
27 display(resultados)
```

Código 4: Reducción de dimensionalidad, selección de atributos y comparación de modelos predictivos

Primero, se aplicó PCA (Análisis de Componentes Principales), reduciendo el conjunto de variables originales a un nuevo espacio de menor dimensión que conserva el 99% de la varianza explicada. Esta transformación se aplicó tanto al conjunto de entrenamiento como al de prueba, y luego se evaluaron los modelos utilizando los datos transformados.

Posteriormente, se utilizó LDA (Análisis Discriminante Lineal), para lo cual fue necesario convertir la variable objetivo continua (Precio) en categorías discretas. Esto se hizo mediante el uso de `pd.cut`, dividiendo los precios en rangos de 50 millones de pesos. LDA redujo los datos a 2 dimensiones, y nuevamente se evaluó el desempeño de los modelos sobre esta versión reducida.

Luego de ejecutar el código, se presentan los resultados de la evaluación de modelos predictivos con y sin reducción de dimensionalidad, tanto de forma visual (gráficos de dispersión) como cuantitativa (métricas de rendimiento).



Cuadro 5: Gráficos de dispersión entre precio real y predicho para cada modelo y técnica de reducción

Reducción	Modelo	R^2	MAE	RMSE
Sin reducción	Regresión Lineal	0.646	63.38 millones	84.00 millones
Sin reducción	KNN	0.427	88.86 millones	106.79 millones
PCA	Regresión Lineal	0.646	63.38 millones	84.00 millones
PCA	KNN	0.427	88.86 millones	106.79 millones
LDA	Regresión Lineal	0.645	63.24 millones	84.03 millones
LDA	KNN	0.691	59.07 millones	78.42 millones

Cuadro 6: Métricas de desempeño para cada modelo y técnica de reducción

Al analizar de forma conjunta las métricas de evaluación y los gráficos de dispersión, se puede observar que el modelo que entrega los mejores resultados es KNN con reducción por LDA. Este modelo presenta el mayor coeficiente de determinación ($R^2 = 0,691$), el menor error absoluto medio (MAE ≈ 59.07 millones) y el menor error cuadrático medio (RMSE ≈ 78.42 millones), superando tanto a la regresión lineal como a KNN en los otros escenarios.

Desde el punto de vista visual, en los gráficos de dispersión también se aprecia que KNN con LDA tiene una mejor alineación de los puntos respecto a la línea de referencia (predicción ideal), mostrando menor dispersión en comparación con sus equivalentes sin reducción o con PCA. Esto sugiere que LDA logra proyectar las variables originales a un espacio más representativo para la predicción del precio, especialmente útil para un algoritmo como KNN, que depende fuertemente de la estructura geométrica del espacio de características.

En contraste, los modelos entrenados sobre los datos sin reducción o con PCA presentan desempeños similares, tanto en las métricas como en los gráficos. De hecho, los resultados de regresión lineal con y sin PCA son prácticamente idénticos, lo cual indica que la reducción de dimensionalidad mediante PCA no aportó mejoras significativas en este caso.

En resumen, se concluye que la combinación de LDA y KNN ofrece el mejor desempeño predictivo en este escenario, tanto por sus resultados cuantitativos como por la coherencia visual observada en los gráficos. Esta combinación demuestra ser una alternativa robusta y eficaz para predecir precios de propiedades a partir de sus atributos estructurales y geográficos.

6.5. Dashboards




Figura 17: Dashboard General 1

A continuación, se construyó un *dashboard* exploratorio con el objetivo de visualizar en conjunto las relaciones clave entre las variables y validar decisiones tomadas durante el preprocesamiento y diseño del modelo. En primer lugar, los histogramas muestran que la distribución del **Precio** total es relativamente uniforme, sin grandes concentraciones en rangos específicos, mientras que la distribución del **Precio_m2** presenta una asimetría hacia la derecha, con una alta frecuencia en valores bajos. Esta diferencia justifica la creación de dicha variable, ya que permite identificar patrones más consistentes y valores

atípicos que no serían evidentes solo observando el precio total.

Por otra parte, la matriz de correlación revela que las variables originales tienen muy baja correlación lineal con el **Precio**, excepto **Precio_m2**, lo que respalda su utilidad como predictor más directo.

Complementando este análisis, el *boxplot* de **Precio** según número de **Habitaciones** muestra que no existe una variación clara en el precio mediano al aumentar la cantidad de habitaciones, indicando que esta variable por sí sola tiene bajo poder explicativo. Finalmente, los *scatterplots* muestran dos patrones relevantes: la relación entre **Precio** y **Metros Útiles** es muy dispersa, con alta variabilidad vertical, mientras que la relación entre **Precio** y **Precio_m2** presenta una estructura más definida, donde valores altos de **Precio_m2** tienden a concentrarse en propiedades de alto valor.

En conjunto, este *dashboard* refuerza decisiones clave tomadas en el diseño del modelo, como la creación de variables derivadas, la selección de predictores relevantes y la exclusión de variables redundantes.

Por último se realizó un segundo dashboard con los resultados de los modelos entrenados:




Figura 18: Dashboard 2

A partir de este panel gráfico se reafirma que la combinación KNN + LDA entrega el mejor desempeño, evidenciado por la mayor concentración de puntos cercanos a la línea de predicción ideal. Los modelos con PCA y sin reducción muestran comportamientos similares, especialmente en regresión lineal, lo que indica que PCA no aportó mejoras significativas en este caso. En contraste, LDA logró una transformación más informativa para KNN, mejorando notablemente su capacidad predictiva.

7. Manual de instalación

El sistema de análisis de precios inmobiliarios fue desarrollado en Python utilizando Google Colab, una plataforma gratuita basada en la nube que permite ejecutar código en bloques sin necesidad de instalaciones locales. A continuación, se detallan los pasos necesarios para ejecutar correctamente el proyecto desde cualquier navegador web.

7.1. Requisitos previos

Antes de iniciar, se deben cumplir los siguientes requisitos:

- Tener una cuenta activa de Google.
- Contar con acceso a internet y navegador actualizado.
- Disponer del archivo `viviendas_chile.csv` cargado en la carpeta Colab Notebooks de Google Drive.

7.2. Pasos de instalación y ejecución

1. Ingresar a Google Colab desde el siguiente enlace: <https://colab.research.google.com>
2. Crear un nuevo notebook o subir el notebook entregado junto al proyecto.
3. En la primera celda del notebook, montar Google Drive con el siguiente código:

```
1 from google.colab import drive
2 drive.mount('/content/drive')
```

Esto solicitará autorización para acceder a tu cuenta de Google. Una vez completado, podrás acceder a tus archivos de Drive.

4. Verifica que el archivo `viviendas_chile.csv` se encuentre en la ruta en la que tu tengas guardado el archivo, a modo de ejemplo:

```
/content/drive/My Drive/Colab Notebooks/viviendas_chile.csv
```

5. Cargar el archivo en una celda con:

```
1 import pandas as pd
2 ruta = '/content/drive/My Drive/Colab Notebooks/
   viviendas_chile.csv'
3 data = pd.read_csv(ruta)
4 print("Datos cargados correctamente")
```

6. Ejecutar el resto del código por bloques según el orden presentado en el notebook (carga de datos, EDA, modelado, visualizaciones y dashboards).
7. Para visualizar dashboards y resultados, simplemente ejecutar cada bloque y observar los gráficos generados directamente en la interfaz de Colab.

7.3. Notas adicionales

- El sistema fue diseñado para funcionar completamente en Google Colab, por lo que no se requiere instalación de software adicional en el computador del usuario.
- En caso de errores relacionados con la ruta del archivo, asegúrese de que el nombre y ubicación del dataset sean correctos.
- El código está comentado y estructurado para permitir su modificación o extensión en caso de nuevos requerimientos.

Con estos pasos, cualquier usuario con conocimientos básicos en Python podrá ejecutar, visualizar y replicar el sistema completo de análisis inmobiliario descrito en este proyecto.

8. Manual de uso

Este sistema permite analizar, modelar y predecir el precio de venta de departamentos en Chile utilizando técnicas estadísticas y de aprendizaje automático. Está pensado tanto para usuarios con formación técnica como para analistas del rubro inmobiliario que deseen obtener una herramienta de soporte a la toma de decisiones basada en datos.

8.1. ¿Qué puede hacer el sistema?

El sistema permite:

- Importar y limpiar un dataset de propiedades en venta.
- Analizar estadísticamente las variables del dataset (EDA).
- Visualizar relaciones entre variables mediante gráficos (correlación, histogramas, boxplots, pairplots).
- Crear una nueva variable `Precio_m2` para mejorar la comparabilidad entre propiedades.
- Entrenar modelos predictivos (Regresión Lineal y KNN) para estimar el precio de una propiedad.
- Aplicar técnicas de reducción de dimensionalidad (PCA y LDA) y comparar el rendimiento de los modelos.
- Generar visualizaciones que permiten interpretar fácilmente los resultados (dashboards).

8.2. ¿Cómo usar el sistema paso a paso?

Una vez abierto el notebook en Google Colab (ver manual de instalación), se deben seguir los siguientes pasos:

1. **Montar Google Drive:** Para acceder al archivo `viviendas_chile.csv`.
2. **Ejecutar la carga del dataset:** Verifica que el archivo está correctamente ubicado y carga los datos con `pandas`.
3. **Limpieza de datos:** Ejecuta las celdas que eliminan duplicados, filtran solo departamentos y convierten las variables categóricas a numéricas (por ejemplo, “Sí” a 1 y “No” a 0).
4. **Análisis exploratorio:** Ejecuta las celdas del EDA para obtener métricas estadísticas, gráficos y detectar outliers. Esto permite comprender cómo se comportan las variables del dataset.
5. **Aplicación de modelos:** Ejecuta los bloques donde se entrena la regresión lineal y el modelo KNN. El sistema muestra los resultados predichos vs reales, así como métricas de evaluación.

6. **Reducción de dimensionalidad y comparación:** Ejecuta las celdas que aplican PCA y LDA, y observa cómo cambia el rendimiento de los modelos.
7. **Visualización de resultados (Dashboards):** Ejecuta las celdas finales para ver gráficos resumen del análisis y del desempeño de los modelos.

8.3. Posibles errores y advertencias

- **Ruta incorrecta del dataset:** Asegúrese de que el archivo `viviendas_chile.csv` se encuentra en la ruta especificada. Si no es así, actualice la variable `ruta` con la ubicación correcta.
- **Modelo de regresión logística no incluido:** Aunque se menciona como opción en el planteamiento inicial, no se implementó debido a que este modelo está diseñado para clasificación y no para predicción de precios (variable continua).
- **Dependencia de Google Colab:** El sistema fue desarrollado y probado exclusivamente en Google Colab. No se asegura el correcto funcionamiento en otros entornos sin ajustes previos.
- **Variables geográficas limitadas:** La variable “Comuna” fue codificada, pero no se incorporaron coordenadas o mapas, lo cual limita el análisis espacial más fino.
- **Resultados dependen del dataset:** Si se modifica el archivo `viviendas_chile.csv`, los resultados pueden variar drásticamente. Asegúrese de validar la calidad del nuevo dataset antes de ejecutar los modelos.

Con esta guía, cualquier persona con nociones básicas de Python puede utilizar el sistema para estimar precios de propiedades y tomar decisiones informadas en el ámbito inmobiliario chileno.

9. Conclusión

El desarrollo de este sistema de análisis de datos inmobiliarios permitió cumplir con el objetivo principal del proyecto: construir una herramienta capaz de procesar, explorar y modelar datos de propiedades en venta, con énfasis en la predicción de precios en función de múltiples atributos.

A lo largo del trabajo, se abordaron distintas etapas fundamentales: desde la carga y limpieza del dataset original hasta la aplicación de técnicas de análisis exploratorio, visualización de datos y entrenamiento de modelos predictivos como regresión lineal y KNN. Este enfoque permitió no solo comprender los factores que más influyen en el valor de una propiedad, sino también generar un modelo funcional capaz de entregar estimaciones cercanas a la realidad.

La herramienta desarrollada se ejecuta completamente en Google Colab, lo que facilita su uso y acceso desde cualquier dispositivo con conexión a internet, eliminando la necesidad de instalaciones adicionales. Esto refuerza la utilidad práctica del sistema para su implementación en contextos reales, especialmente por parte de empresas del rubro inmobiliario que requieren tomar decisiones estratégicas basadas en evidencia.

Finalmente, el proceso de desarrollo y validación permitió identificar fortalezas del sistema, como su flexibilidad, claridad visual y buen desempeño en tareas de regresión. También se reconocieron posibles áreas de mejora, como la incorporación de modelos más avanzados o el análisis espacial más detallado. Aun así, el sistema cumple con todos los requerimientos establecidos, logrando una solución robusta y funcional dentro del alcance planteado.

10. Bibliografía

- [1] Lee, G. Y., Alzamil, L., Doskenov, B., & Termehchy, A. (2021). A Survey on Data Cleaning Methods for Improved Machine Learning Model Performance. arXiv preprint arXiv:2109.07127. Recuperado de <https://arxiv.org/abs/2109.07127>
- [2] GeeksforGeeks. (2025). *What is Data Science?* Recuperado de <https://www.geeksforgeeks.org/data-science/>